

تمرین دوم پایتون شبکه‌های عصبی بهار ۱۴۰۲

آریا ابراهیمی ۹۸۲۲۷۶۲۱۷۵

هدف از این تمرین، بررسی انتقال دانش در شبکه‌های عصبی عمیق می‌باشد. برای این کار از سه شبکه VGG16، ResNet50 و DenseNet121 آموزش داده شده بر روی ImageNet استفاده می‌کنیم. شبکه‌های یادگیری شده در لایه ابتدایی شامل فیچرهای ابتدایی تر می‌شوند و هرچقدر عمیق‌تر می‌شوند، ویژگی‌های پیچیده‌تری را شامل می‌شوند. هدف این است تا با استفاده از وزن‌های یادگیری شده لایه‌های ابتدایی با تعداد داده کمتر و سرعت بیشتری بتوانیم classification را انجام دهیم.

در این تمرین با استفاده از داده‌های سگ و گربه، عمل کرد شبکه‌های معرفی شده را با درصد‌های متفاوت لایه‌های freeze شده بررسی می‌کنیم. در نهایت ویژگی‌های یادگیری شده مربوط به داده‌ها را به یک RandomForestClassifier می‌دهیم و تسک نهایی مربوط به classification را با استفاده از آن نیز انجام می‌دهیم و با classification انجام شده توسط تک نورون لایه آخر شبکه مقایسه می‌کنیم.


۱- بخش اول

همان‌طور که در جدول ۱ مشاهده می‌شود، هرچقدر تعداد لایه‌های trainable بیشتر شود، میزان accuracy مدل کمتر می‌شود و بهترین عمل کرد مربوط به تعداد لایه‌های قابل یادگیری ۱۰ درصد و ۳۰ درصد می‌باشد و این برای هر سه شبکه VGG16 و ResNet50 و DenseNet121 برقرار است. می‌توان نتیجه گرفت که انتقال دانش می‌تواند به یادگیری بهتر کمک کند و اگر داده زیادی برای آموزش یک شبکه نداریم، استفاده از یک شبکه از پیش آموزش داده شده می‌تواند از overfit شدن و مشکلات دیگر جلوگیری کند.


جدول ۱: دقت شبکه‌های انتقال دانش یافته از مدل‌های گفته شده بعد از سه epoch بر روی دیتاست سگ و گربه.

Model	VGG16					ResNet50					DenseNet121				
Trainable	10%	30%	50%	70%	100%	10%	30%	50%	70%	100%	10%	30%	50%	70%	100%
Train Accuracy	98.51	98.75	97.9	96.57	97.04	99.57	99.64	99.51	99.08	99.23	99.46	99.49	99.48	99.44	99.26
Validation Accuracy	98.27	97.08	95.80	96.69	97.37	98.75	98.68	98.66	98.22	97.63	99.13	99.15	99.03	97.99	98.83


همان‌طور که مشاهده می‌شود در مجموع DenseNet121 عملکرد بهتری نسبت به دو مدل دیگر دارد و در هر مدل هم لایه‌های قابل یادگیری بین ۱۰ درصد تا ۳۰ درصد بهترین نتیجه را نمایش می‌دهند و همچنین نسبت به کانفیگ‌های دیگر سریع‌تر یاد می‌گیرند.



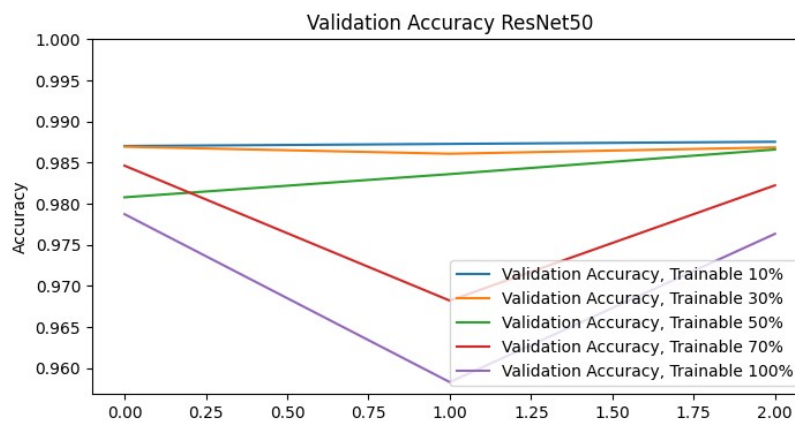
شکل ۱: دقت Training برای شبکه‌های انتقال دانش یافته از VGG16



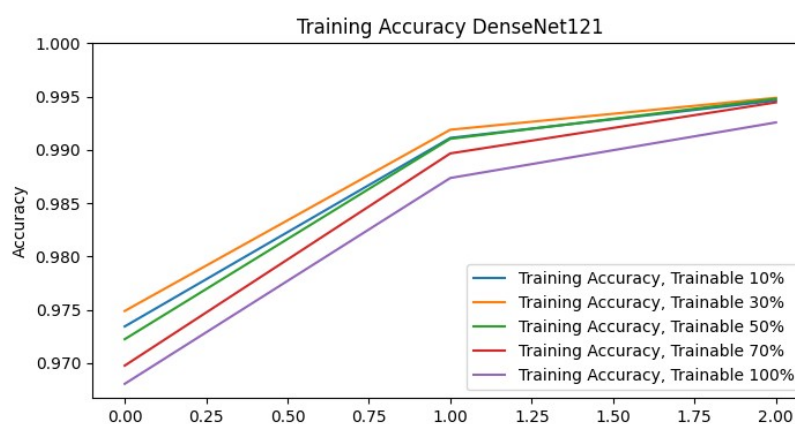
شکل ۲: دقت Validation برای شبکه های انتقال دانش یافته از VGG16




شکل ۳: دقت Training برای شبکه های انتقال دانش یافته از ResNet50



شکل ۴: دقت Validation برای شبکه های انتقال دانش یافته از ResNet50



شکل ۵: دقت Training برای شبکه های انتقال دانش یافته از DenseNet121




شکل ۶: شکل ۵: دقت Validation برای شبکه های انتقال دانش یافته از DenseNet121

سوالی که پیش می آید این است که آیا اگر تمامی لایه های مدل اصلی را freeze کنیم نسبت به نتایج فعلی خروجی بهتری خواهیم داشت؟ نتایج به دست آمده برای زمانی که تمامی لایه ها را freeze کنیم در جدول ۲ قابل مشاهده است.


جدول ۲: انتقال دانش بعد از سه epoch زمانی که تمامی لایه ها freeze شوند

Model	VGG16	ResNet50	DenseNet121
Train Accuracy	98.46	99.17	99.26
Validation Accuracy	97.18	98.78	98.99


همان طور که مشاهده می شود در حالتی که تمامی لایه های شبکه های گفته شده freeze شوند، نتیجه بهتری مشاهده نمی شود.



شکل ۷: انتقال دانش با استفاده از مدل VGG16 و ۳۰ درصد لایه های trainable در پنج epoch



شکل ۸: انتقال دانش با استفاده از مدل ResNet50 و ۳۰ درصد لایه های trainable در پنج epoch



شکل ۹: انتقال دانش با استفاده از مدل *DenseNet121* و ۳۰ درصد لایه های *trainable* در پنج *epoch*

۲- بخش دوم

در این بخش، ویژگی های یادگیری شده مربوط به نسخه ۳۰ درصد شبکه ها را برای همان دیتاست استخراج کرده و با استفاده از *RandomForestClassifier* کتابخانه *SciKit* آن ها را دسته بندی می کنیم. چالشی که در قسمت پیاده سازی این بخش وجود دارد این است که دیتاست را به صورت *BatchDataset* دریافت کرده ایم (شامل داده های یادگیری و لیبل مربوط به آنها) که باعث می شود به راحتی به داده و لیبل دسترسی نداشته باشیم و از طریق متد *take* می توانیم روی *batch* ها پیمایش کنیم. یک راه می تواند این باشد که همزمان با پیمایش روی داده ها، آن ها را به همراه لیبل متناظرشان ذخیره کنیم. این روش رم زیادی اشغال می کند و باعث کرش کردن محیط *Google Colab* می شود.


راه دیگر این است که *RandomForestClassifier* را همزمان با پیمایش روی دیتاست به صورت *mini-batch* آموزش دهیم. با این کار دیگر نیازی به ذخیره داده ها نیست ولی زمان بیشتری نیاز دارد.

دقت *RandomForestClassifier* برای داده های *validation* برای سه شبکه در نسخه ۳۰ درصد در جدول ۳ قابل مشاهده است.

جدول ۳: دقت بر روی دیتاست *validation* با استفاده از *RandomForestClassifier*

Model	VGG16	ResNet50	DenseNet121
Validation Accuracy	97.12	98.74	99.25

همان طور که مشاهده می شود، طبقه بندی با استفاده از *RandomForestClassifier* روی ویژگی های استخراج شده از شبکه ها نتایج برابر و حتی در مواردی بهتر از *classification* خود شبکه ها ارائه می دهد.



شکل ۱۰: ویژگی‌های کاهش *dimensionality* داده شده توسط *PCA* و یادگیری شده توسط شبکه (قبل از اعمال تابع فعال‌ساز *relu*)

می‌توان نتیجه گرفت که مهم‌ترین کاری که شبکه‌ها انجام می‌دهند این است که ویژگی‌یاد می‌گیرند و شاید تسک *classification* را طبقه‌بندی مثل *RandomForestClassifier* بهتر انجام دهد ولی چیزی که شبکه‌های عصبی را متمایز می‌کند و باعث می‌شود خوب عمل کنند، ویژگی‌های یادگیری شده خوب است.